

COSMIC DATA WATCHERS

Descubrimiento inteligente de familias de exoplanetas

Motor de clustering no supervisado sobre catálogos del NASA Exoplanet Archive


Equipo: Laura · Elena · Jose · Elena D. · Elizabeth

Qué es ExoProfiler

Un motor que toma catálogos de exoplanetas sin etiquetar y los organiza automáticamente en familias de mundos.

Sin reglas fijas ni categorías predefinidas.
Encuentra la estructura que ya está escondida en los datos.

675 exoplanetas · 12 variables · 4 familias identificadas



¿Por qué importa?

🕒 **Tiempo de telescopio = recurso escaso y muy costoso**

Apuntar un instrumento de última generación a un punto del espacio tiene un coste real altísimo.

🔍 **Filtrado automático por perfil de interés**

ExoProfiler agrupa automáticamente exoplanetas con características similares, ayudando a priorizar qué candidatos merece la pena estudiar.

👥 **¿A quién sirve?**

- **Observatorios y equipos de investigación** que necesitan priorizar qué exoplanetas estudiar con telescopios.
- Equipos que gestionan **grandes catálogos** astronómicos y requieren un **primer análisis** automático de los datos.
- **Investigadores** que buscan **anomalías** o candidatos poco habituales para revisarlos con mayor profundidad



ExoProfiler ayuda a transformar miles de observaciones en decisiones concretas: qué grupos estudiar, qué datos revisar y qué planetas priorizar para nuevas observaciones con telescopio.

**Antes de contaros cómo lo construimos,
queremos que lo veáis en acción.**

▶ Demo en vivo / Vídeo de respaldo

El desafío original

Catálogos enormes de exoplanetas sin estructurar:
sin categorías, sin etiquetas.

Analizar planeta por planeta, a mano, no escala.

Fuente: catálogo TESS del NASA Exoplanet Archive.
Datos reales, públicos, verificables.

⚠ El mayor reto de imputación

Variable `pl_insol` (insolación): 50.67% de valores ausentes

910

planetas de partida

Dificultades enfrentadas

910 Planetas originales en el catálogo TESS

– **171** Excluidos por ser de 2026 (mediciones incompletas)

= **739** Elegibles hasta 2025

– **64** Excluidos por tener < 8 de 12 variables medidas

= **675** Dataset final: 0 nulos, 0 duplicados

Pipeline de análisis

Pipeline ExoProfiler



Datos → EDA → Preprocesamiento → PCA → Clustering → Perfilado

Cada paso documentado en notebooks reproducibles (01–05).

Preprocesamiento

Outliers como señal

No se eliminan: en astronomía, un planeta "raro" puede ser el hallazgo más interesante.

Transformaciones

log1p en 6 variables sesgadas + RobustScaler para respetar valores extremos.

Imputación KNN

Comparamos Mediana vs KNN (5 vecinos):

Método	RMSE	Elegido
Mediana	0.7829	
KNN (5 vecinos)	0.4718	✓

KNN reduce el error a la mitad → elegido

Reducción de dimensionalidad — PCA


12 variables → 4 componentes →
90.2% varianza

PC1 (44.0%): Escala orbital

PC2 (30.2%): Gradiente térmico-estelar


PC3 (9.6%): Excentricidad

PC4 (6.4%): Metalicidad y tamaño planetario



Selección de K — ¿Cuántas familias?

Evaluación de K (2-10) sobre 4 componentes PCA



K=4 óptimo · Silhouette = 0.3278 (máximo) · Inercia = 2223.46
Evaluado K de 2 a 10 — máxima cohesión y separación en K=4

Validación cruzada — 3 métodos independientes

K-Means

Silhouette: 0.3278
100% estabilidad
entre semillas

Jerárquico (Ward)


98.52% coincidencia
Silhouette: 0.3138

DBSCAN

18.07% ruido/outlier
Confirma núcleo denso
+ periferia dispersa

Tres métodos con lógicas matemáticas independientes → misma estructura.
Eso nos da confianza real.

Las 4 Familias de Mundos



La Familia 3 (Rocosos/Super-Tierras) agrupó al 50% de los planetas.

La Familia 2 es un solo planeta: un objeto tan distinto que ningún algoritmo lo confunde.

Es exactamente el tipo de anomalía que detecta ExoProfiler.

Limitaciones de los datos

⚠ Sesgo del método de tránsito

TESS detecta preferentemente planetas grandes y de órbita corta.
Planetas pequeños o de órbita larga están infrarrepresentados.
No es un fallo del modelo: es un sesgo heredado del método de observación.

⚠ Disponibilidad desigual de mediciones

pl_insol: 50.67% ausente · pl_bmasse: 16.59% · pl_orbeccen: 16.00%
Las conclusiones que dependan fuertemente de estas variables
deben tomarse con cautela.

Interpretación responsable

Clusters ≠ taxonomía oficial

Son patrones matemáticos. Se alinean con la taxonomía de la NASA,
pero no la sustituyen.

Anécdota de rigor

En una fase intermedia, el equipo consideró llamar a un segmento
"mundos templados". Al revisar temperatura e insolación reales,
vimos que era engañoso. Se descartó.

Riesgo de discriminación indirecta

Si se usa para priorizar tiempo de telescopio, el sesgo de detección
podría trasladarse a decisiones reales, penalizando planetas
que ya están peor observados. Lo comunicamos con transparencia.

Rigor técnico + honestidad sobre los límites

= una herramienta que ayuda a tomar decisiones basadas en datos,
para decidir dónde apuntar el siguiente telescopio.

675 exoplanetas reales · 4 familias validadas con 3 métodos
90.2% de varianza preservada · Anomalías identificadas

Gracias. Quedamos abiertos a preguntas.